嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：基于 Olist 数据的用户价值与销售预测分析

学　　院：数据科学学院

专业班级：大数据 242

学　　号：2024459985224

姓　　名：段胤臣

完成日期：2026 年 11 月

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；②README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

数 据 科 学 学 院

基于 Olist 数据的用户价值与销售预测分析

（嘉兴大学 数据科学学院）

摘　要

电商平台的精细化运营，离不开对客户价值与销售趋势的量化洞察。本文基于 Kaggle 官方公开的 Olist 巴西电商数据集为对象，其中包含 99,441 张订单、成交额约 1,322 万雷亚尔。数据通过官方文件下载这一白名单方式合规获取数据，经缺失值、异常值、重复值治理与多表主外键对齐后，构建了 11 万行级分析主表。在此基础上，本文综合运用 RFM 八分类、同期群留存、波士顿矩阵、SARIMA 预测、Apriori 关联规则与帕累托 ABC 分类六种模型展开分析，并基于分析结果用 Matplotlib 与 Pyecharts 复现 15 种可视化模板，产出 8 张业务模型图和 1 个含 14 个分析组件的交互式大屏。研究后发现：平台 GMV 高速增长，其中 2018H1 同比 +181.6%，但复购率仅 3.0%、次月留存仅 5.45%；前 45% 客户贡献 80% GMV；健康美妆为现金牛品类；SARIMA 回测 MAPE 为 5.58%。据此，本文提出流失召回、复购体系建设、品类组合优化与搭配营销等可落地建议。

关键词：商业数据分析；RFM 模型；SARIMA 预测；Python 可视化；交互式大屏

目 录

1 引言 3
1.1 研究背景 3
1.2 研究目的 3
1.3 研究意义 3
2 数据准备与预处理 4
2.1 数据源介绍 4
2.2 合规获取方式 4
2.3 数据来源合规声明 4
2.4 数据集概述 4
3 数据清洗与治理 5
3.1 数据清洗 5
3.2 数据转换 6
3.3 数据整合 6
4 商业分析模型 7
4.1 模型选型 7
4.2 参数与阈值设定依据 7
4.3 模型计算与验证 8
5 Python 数据分析与可视化 11
5.1 数据探索性分析 11
5.2 可视化模板复现 13
5.3 业务模型图 14
5.4 交互式可视化大屏 19
6 商业案例分析 20
6.1 案例背景 20
6.2 结果解读 21
6.3 商业建议 21
7 结论与展望 22
7.1 研究结论 22
7.2 局限性与展望 22
7.3 AI 使用披露 23
参考文献 24
附录 25

1 引言

1.1 研究背景

近年来，拉丁美洲电子商务保持高速增长的趋势，而巴西作为该区域最大的电商市场，聚集了海量中小卖家与平台型企业。Olist 是巴西知名的电商服务平台，为中小商家提供从店铺入驻、商品上架到物流配送的一站式解决方案，其业务也覆盖巴西全部 27 个州。平台在快速扩张的同时，也面临着获客成本上升、客户留存不足、品类结构失衡等典型成长性问题，亟需通过数据分析将“经验驱动”的运营方式升级为“数据驱动”。

在此背景下，如何从海量交易数据中识别高价值客户、预判销售趋势、优化品类组合，成为平台运营的核心命题。本文完成了从真实数据的获取到交互式大屏呈现的端到端的针对结果的分析，而 Olist 数据集多表关联、字段丰富、规模适中的特点，恰好为 RFM、同期群、波士顿矩阵、时间序列预测等商业分析模型提供了理想载体。

1.2 研究目的

本文以 Olist 平台运营方视角出发，主要围绕三个递进的商业问题展开：其一，平台销售趋势如何演变、未来半年将如何表现？其二，客户价值结构呈何种分布、哪些分层最值得投入运营资源？其三，各品类组合的份额与增速格局如何、跨品类搭配销售存在哪些机会？

围绕上述问题，本文的目标是构建一套“数据获取—清洗治理—模型分析—可视化呈现—商业洞察”的完整分析流程，同时产出可复现的代码仓库、23 张静态图表、可交互式大屏与以及对应的商业建议。

1.3 研究意义

从方法论层面来看，本文将多种商业分析模型应用于同一真实数据集，检验了不同模型在统一业务场景下的适用边界与组合价值；实践层面，分析结论可直接服务于平台的客户分层运营、品类资源分配与大促备货等对应工作的决策；工程层面，项目以规范的目录结构、一键复现脚本与完整文档归档，形成并取得了具备教学参考价值的开源项目成果。

2 数据准备与预处理

2.1 数据源介绍

本文主数据源为 Kaggle 平台官方发布的“Olist Brazilian E-Commerce Public Dataset”，其对应的 URL 为：https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce。数据集由 Olist 官方脱敏发布，包含了 2016 年 9 月至 2018 年 9 月的真实交易数据，共 9 张表，分别为：订单主表 99,441 条、订单明细 112,650 条、支付 103,886 条、评价 99,224 条、客户 99,441 条、商品 32,951 条、卖家 3,095 条、地理编码 1,000,163 条及品类葡英翻译对照 71 条，满足“主表记录数不少于 500 条”的规模要求，本文未选用辅助数据源。

2.2 合规获取方式

数据的获取严格采用课程白名单方式：通过 Kaggle 数据集页面的官方公开下载入口一次性获取 ZIP 压缩包，可认为等效于 Kaggle 官方 CLI 的 datasets download 命令，全程未使用 Scrapy、Selenium、requests 网页解析或模拟登录等任何爬虫技术，数据获取环节不涉及任何网页抓取行为。该数据源也同时列于课程附件 A 推荐清单。

2.3 数据来源合规声明

合规声明如下：数据源的名称为 Olist Brazilian E-Commerce Public Dataset；获取方式是通过 Kaggle 官方文件下载；获取日期为 2026 年 11 月 3 日。同时因为数据集采用 CC BY-NC-SA 4.0 授权协议发布，即署名-非商业性使用-相同方式共享。其数据中的客户标识已匿名化为 customer_unique_id，不可直接从其中获取识别个人身份的信息。本项目全部产出仅用于课程学习，不涉商业用途，衍生成果也按同一协议共享。上传的仓库 docs/ 目录下有完整的书面声明文件，可对照查阅。

2.4 数据集概述

数据集以订单主表 olist_orders_dataset 为核心，以主键 order_id 为中心，延伸出了四个方向：订单明细表（order_id 关联商品 product_id 与卖家 seller_id）、

支付表与评价表（order_id 关联）、客户维度表（customer_id 关联，含匿名客户编号 customer_unique_id 与所在城市、州），商品维度表经翻译表映射出英文品类 category_english。清洗阶段按“明细×订单×商品×客户×支付”内连接构建分析主表，同时主外键并不存在缺失情况，逻辑自洽。每张表的字段、类型与缺失率明细由 scripts/01_load.py 自动生成，详情可见 docs/schema 说明.md。

3 数据清洗与治理

原始的九张表的整体完整性较好，但仍存在业务逻辑矛盾、字段缺失与口径噪声等问题。本节将从缺失值、异常值、重复值与口径一致性四个维度展开治理，全部处理规则由 scripts/02_clean.py 固化为代码，每步记录处理前后行数并输出清洗日志，保证治理过程可追溯、可复现。

3.1 数据清洗

数据清洗的对象是原始加载后的九张表，目标是让每一条进入分析的记录在业务上可解释、在关联上可追溯。具体处理分为以下四类。

缺失值治理分三类处理：其一，8 条“状态为已交付但无交付时间”的订单在业务上不可能成立，判定为脏数据予以剔除；其二，商品维度中缺失的品类名称填充为 unknown 以保证关联完整；其三，商品重量、尺寸等数值字段缺失较多且不影响核心分析，以中位数填充。评价文本缺失属“用户未评论”的正常业务形态，予以保留。

异常值治理采用“剔除+标注”双轨策略：价格与运费为负的明细记录违背了基本的商业逻辑，所以在这里选择直接剔除；而对价格字段按 3 倍 IQR 上界，即 420 雷亚尔，识别出了 4,074 条极端高价记录，考虑到高价耐用品订单具有真实业务背景，仅打标 is_price_outlier 而并不将对应的数据删除，避免误伤业务信号。

重复值与口径一致性治理：各表按主键进行去重操作，订单主表、支付表与评价表均未发现重复的主键；明细表中同一 order_id 重复出现多行，经核实后发现是属于同一笔订单中购买的多件商品，属于正常形态，故予以保留。

而在口径一致性方面，全文统一以 order_status=delivered 界定成交、以 order_purchase_timestamp 界定下单时点，同时也核对了支付金额与明细 GMV

的勾稽关系，其中未发现跨表金额矛盾。

经上述治理，分析主表最终保留 112,639 行明细，较原始订单明细 112,650 行仅剔除 11 条问题记录，信息损失可以忽略；全部治理动作只针对脏数据与口径噪声，未对业务分布做任何主观调整，保证后续六种模型的输入与真实交易一致。

3.2 数据转换

在类型统一方面，订单表的 5 个时间字段全部解析为 datetime 类型，同时金额字段均保留两位小数；在日期对齐方面，本文以 order_purchase_timestamp 为分析的基准时间，随后派生出购买日期、月份、自然周、小时、星期（0 表示周一）等粒度字段；而在指标派生方面，计算明细级 GMV（item_gmv）与配送时长（delivery_days，签收时间减下单时间），并约定销售分析仅统计 order_status=delivered 订单，即已完成订单，共 96,469 张，同时取消与不可用订单也进行了保留，用于后续的履约漏斗分析。

3.3 数据整合

针对数据集多表关联的特点，本文采用内连接的策略，即针对订单明细依次关联订单、商品（含品类翻译）、客户与支付聚合表，评价表左连接补充评分，最终主表 112,639 行、关键外键零缺失。因数据规模充足，故本项目未进行抽样，亦无 Faker 补充生成数据；同时图表绘制中的展示性抽样，即散点图 n=5000、随机种子 42，也已在图题中注明。清洗产物同时导出为 CSV 与 SQLite，便于复用与验证。

4 商业分析模型

4.1 模型选型

结合 Olist 数据的多表交易结构以及平台运营场景，本文选用了六种模型构成“趋势—结构—客群—关联—预测”的完整分析链路：趋势与对比层面采用环比/同比与移动平均，回答“增长有多快”；结构与价值层面采用帕累托 ABC 分类与波士顿矩阵，回答“价值集中在哪里、资源投向哪里”；用户与客群层面采用 RFM 八分类与同期群留存分析，回答“谁最有价值、留住了谁”；关联与转化层面采用 Apriori 购物篮分析，回答“商品如何组合”；预测与预警层面采用 SARIMA 时间序列模型，回答“未来卖多少”。

六种模型并非简单堆砌，而是互为印证与输入：其中同期群揭示的低留存解释了 RFM 中 F 维度退化为二值的原因；RFM 锁定的挽留客群与 ABC 的高价值名单共同圈定召回预算的投放对象；BCG 给出的明星/现金牛品类与关联规则给出的搭配组合，共同构成大促选品与推荐位设计的依据；SARIMA 的预测峰值则为上述所有动作提供时间窗口。

4.2 参数与阈值设定依据

（1）RFM 模型。本文将数据最大成交日次日（2018-08-30）定为了快照日。而在切分形式上，R、M 采用了中位数切分，因为 R 与 M 均呈现出右偏分布的特点，故均值容易受到极端值的牵引而产生偏差，中位数（R=219 天、M=90 雷亚尔）能保证两组样本量大致均衡且对偏态稳更加健。同时本文将 F 的中位数退化为 1，这是基于复购客户仅 3.0% 做出的调整，若机械套用中位数切分会使的全部客户落入同一组，这样也就失去了划分意义，故按业务关键信号“是否复购（F>1）”切分——复购是客户从“交易型”转向“关系型”的分水岭，也是分层运营的核心抓手。R、F、M 三维度高低组合成经典八分类，即可得到八个不同的客户分层。

（2）同期群模型。按客户首购月份划分同期群，月龄 m 取 0–12，留存率定义为该群在第 m 月仍有下单的客户数占群规模之比；观察期统一 12 个月，避免不同群之间因观察窗口不同而不可比。

（3）波士顿矩阵。增速口径为 2018H1 对 2017H1 同比，刻意避开 2016 年尾与 2018 年 9 月等不完整月份，防止口径噪声污染增速；相对市场份额 = 品类份额 ÷ 最大品类份额，即采用了经典 BCG 定义，同时将横轴阈值取 0.5，纵轴阈值取 20 个主力品类的增速中位数（31.7%），保证四象限划分与平台自身增长水平相适应。

（4）SARIMA 模型。序列取 2017-01 至 2018-08 共 20 个月的完整月度 GMV。定阶 (p,d,q)(P,D,Q)s=(1,1,1)(1,0,1,12)：一阶差分 d=1 消除长期趋势，周期 s=12 捕捉年度季节性，非季节与季节 AR/MA 各取一阶，经 AIC 网格比较为较优且最简洁的组合；关闭平稳性与可逆性强制约束以适应短序列。回测采用“前 14 个月训练、后 6 个月测试”的时间外推方式，误差指标为 MAPE 与 RMSE。

（5）Apriori 关联规则。全量订单中品类共现支持度不足 0.1%（单均约 1.2 件），直接挖掘无法产生有效规则，故按购物篮分析惯例，在 780 个多品类订单子集上挖掘，min_support=2%（约 16 单，保证规则非偶然共现）、min_confidence=15%，并按提升度降序排列，重点解释其中 lift＞1 的正向关联规则。

（6）帕累托 ABC 分类。本文在这里将客户累计消费降序排列，以累计 GMV 占比 80%、95% 为双阈值划分出 A、B、C 三级，同时阈值沿用帕累托分析的通行惯例，而三级对应的运营含义分别为重点维护、常规运营以及长尾覆盖，三种资源的投入强度依次递减。

4.3 模型计算与验证

（1）RFM 计算与结果。指标定义为：R = 快照日 − 客户最近购买日（天）；F = 客户去重订单数；M = 客户明细 GMV 之和。计算覆盖 93,349 名独立客户，八分类汇总见表 1：重要发展客户（22,355 人，近期新客、单次高消费）与重要挽留客户（21,973 人，约 365 天未回购的历史高消费客户）分别贡献 39.17% 与 38.85% 的 GMV，合计近八成，构成了平台价值基本盘；而重要价值与重要保持客户合计仅 2,343 人，但人均消费近 300 雷亚尔、平均购买 2 次以上，故在这里可认为是验证了复购客户的单位经济价值显著更优，在本文后续也多次使

用了这一特性。

客户分层	客户数	平均最近购买天数	平均购买次数	平均消费金额(雷亚尔)	GMV 占比(%)
重要发展客户	22,355	112.35	1.00	231.65	39.17
重要挽留客户	21,973	365.21	1.00	233.71	38.85
一般挽留客户	23,283	364.71	1.00	47.23	8.32
一般发展客户	22,937	111.92	1.00	47.01	8.16
重要价值客户	1,316	113.33	2.16	299.87	2.99
重要保持客户	1,027	348.69	2.08	297.34	2.31
一般价值客户	233	110.88	2.03	62.17	0.11
一般保持客户	225	373.20	2.06	61.88	0.11

表 1　RFM 八分类客户汇总

（2）同期群计算与结果。按客户首购月份把人群切成 22 个同期群，随后对首购同期群计算 12 月龄留存率矩阵：次月（M+1）的平均留存仅 5.45%，M+6 降至 0.27%、M+12 仅 0.21%，且各群留存曲线形态高度一致——这说明低留存是平台层面的系统性特征，而非个别月份的经营波动。而 2017 年 8—11 月的新客群次月留存（0.6%–0.7%）则略高于早期，这表明大促期间所吸引来的新客的质量略有改善，但远未形成稳定且可持续的复购机制。

（3）波士顿矩阵计算与结果。矩阵里是 20 个主力品类，横轴对应相对份额、纵轴对应同比增速。在 20 个主力品类中：健康美妆（相对份额 1.00、增速 +59.5%）、腕表礼品（0.91、+44.6%）落入现金牛象限；家居用品（0.52、+76.1%）跨越至明星象限边缘，汽车配件（0.45、+46.4%）与母婴用品（0.31、+68.5%）处于高增长、待提份额的问题/明星过渡带；玩具、酷玩好物份额低且同比负增长，落入瘦狗象限。矩阵结果可直接支撑第 6 章的品类预算再分配建议。

（4）SARIMA 回测与预测。回测结果见表 2：MAPE=5.58%、RMSE=71,618 雷亚尔，若拆分开来看，6 个测试月中有 3 个月误差低于 3%，误差主要来自 2018 年 3—5 月平台 GMV 快速抬升阶段所造成的趋势低估。在对全样本重新进行拟合后输出未来 6 个月点预测与 95% 置信区间（表 3）：在这里预测 2018 年 11 月受黑五拉动达 98.7 万雷亚尔，与 2017 年 11 月实测峰值 98.8 万高

度接近，所以可认为季节项捕捉有效；而置信区间随预测期延长走阔，这提示了对于中长期的预测应谨慎使用。

月份	实际 GMV(雷亚尔)	预测 GMV(雷亚尔)	绝对误差率(%)
2018-03	953,356	888,536	6.80
2018-04	973,534	850,097	12.68
2018-05	977,545	873,890	10.60
2018-06	855,592	859,162	0.42
2018-07	867,486	868,279	0.09
2018-08	838,577	862,636	2.87

表 2　SARIMA 回测结果（MAPE=5.58%，RMSE=71,618）

月份	点预测 GMV(雷亚尔)	95%置信下界	95%置信上界
2018-09	836,807	613,803	1,059,812
2018-10	848,975	466,777	1,231,174
2018-11	987,069	483,772	1,490,366
2018-12	879,765	277,490	1,482,040
2019-01	958,718	271,263	1,646,173
2019-02	908,791	145,550	1,672,032

表 3　SARIMA 未来 6 个月点预测与 95% 置信区间

（5）关联规则计算与结果。在本文中将支持度、置信度、提升度分别定义为：$\text{support}(A\to B)=P(A\cup B)$，$\text{confidence}(A\to B)=P(B|A)$，$\text{lift}(A\to B)=\text{confidence}(A\to B)\div P(B)$。在多品类订单子集上共得到 12 条规则，排在前 5 见表 4：其中家居舒适→床浴桌台置信度高达 86.0%、lift=3.30，即购买家居舒适品的客户购买床浴桌台的概率是该品类基准购买率的 3.3 倍；而玩具↔母婴（lift=3.12）、母婴→酷玩好物（lift=2.50）构成了一个母婴场景的连带组合，均为正向强关联，可直接转化为推荐位与捆绑策略。

前项 A	后项 B	支持度(%)	置信度(%)	提升度 lift
家居舒适	床浴桌台	5.51	86.00	3.30
床浴桌台	家居舒适	5.51	21.18	3.30
玩具	母婴用品	2.44	37.25	3.12

母婴用品	玩具	2.44	20.43	3.12
母婴用品	酷玩好物	2.56	21.51	2.50

表 4　Apriori 跨品类关联规则 Top5（多品类订单子集）

（6）ABC 分类结果。A 类（高价值）客户共有 42,003 人，约占总数的 45.0%，贡献了 80.0% 的 GMV，B 类 28,392 人（30.4%）贡献 15.0%，C 类 22,954 人（24.6%）仅贡献 5.0%。与 RFM 交叉验证可见：A 类主体正是重要发展与重要挽留两大分层，两条独立分析路径得出一致结论——平台的客户运营资源应聚焦于头部的约半数客户，而非平均分配。

5 Python 数据分析与可视化

5.1 数据探索性分析

趋势维度（图 1、图 2）：平台 GMV 自 2017 年初约 12 万雷亚尔/月一路攀升至 2018 年的 85 万雷亚尔/月以上，2018H1 同比增长了 181.6%；2017 年 11 月黑五大促达 98.8 万雷亚尔、环比增长 52.4%，为观测期峰值，12 月随即回落至 72.6 万（环比 −26.5%），显示大促对次月需求存在一定透支。3 期移动平均平滑后，序列呈“2017 高速扩张—2018 高位平台”的两阶段特征：2018 年 3—5 月连续站上 95 万后，6—8 月稳定在 85 万附近，平台由增量市场转入存量竞争的信号非常明确，这也是本文后段将分析重心转向客户价值挖掘的直接原因。

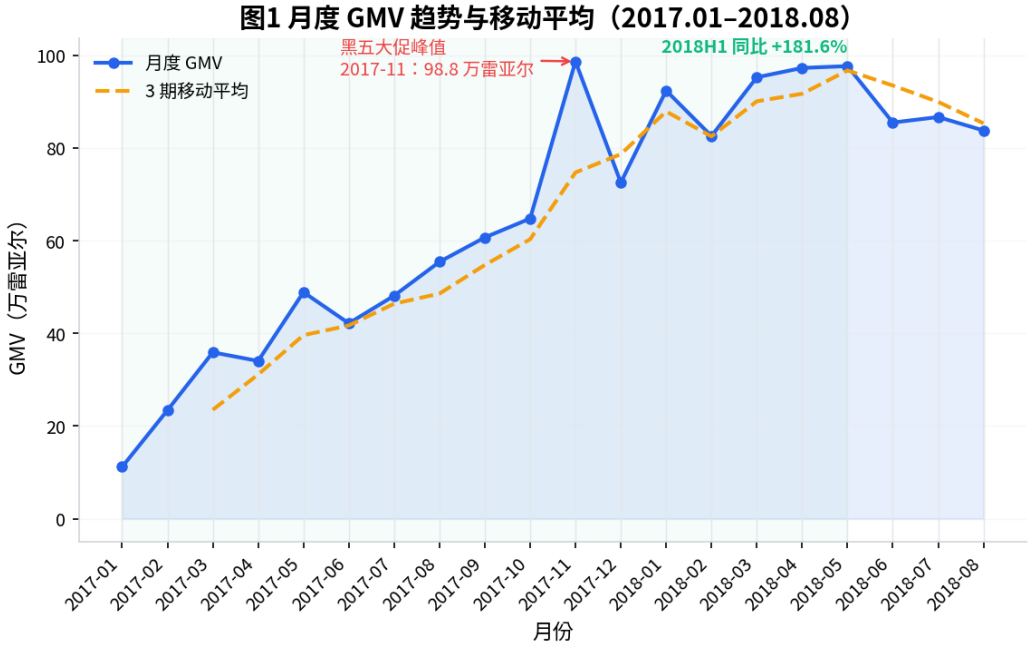


图 1　月度 GMV 趋势与移动平均（标注黑五峰值与同比增速）

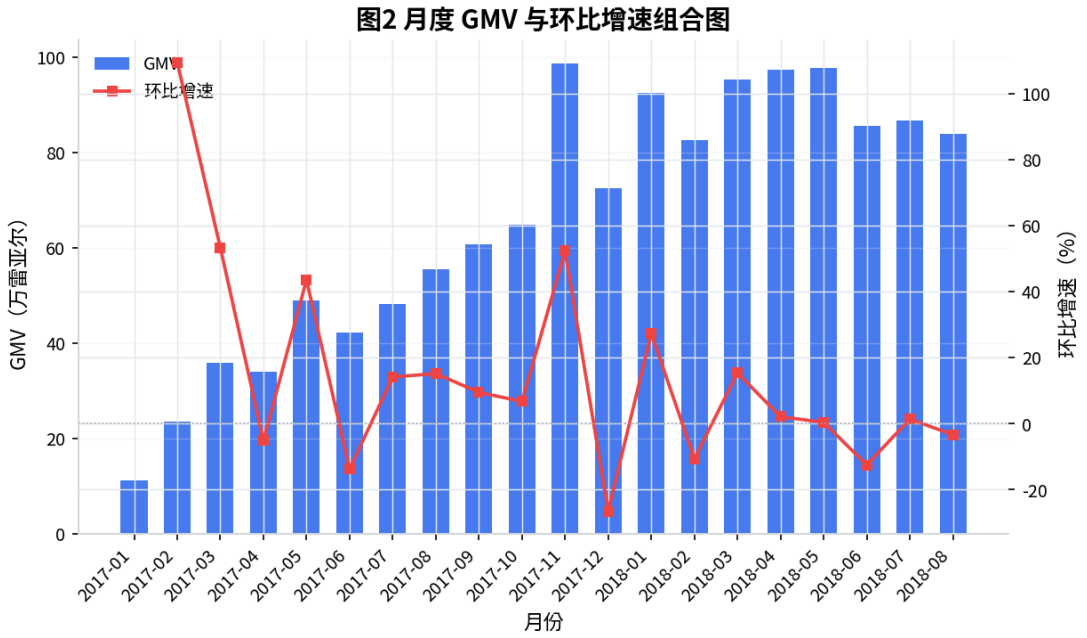


图 2　月度 GMV 与环比增速组合图

结构与行为维度（图 3、图 4）：健康美妆、腕表礼品、床浴桌台三大品类合计贡献 25.9% 的 GMV。而地域角度上来看，圣保罗州独占 38.2%、远超第二名里约热内卢，体现出了极为明显的头部集中效应。而从时段上来看，工作日 10—16 时为下单高峰，周末的热度则整体回落，这也符合巴西消费者“工作时间网购”的行为特征，推送与客服资源可按此时段排布。订单金额中位数约 105 雷亚尔、右偏明显，与 RFM 中 M 的偏态分布也互为印证。

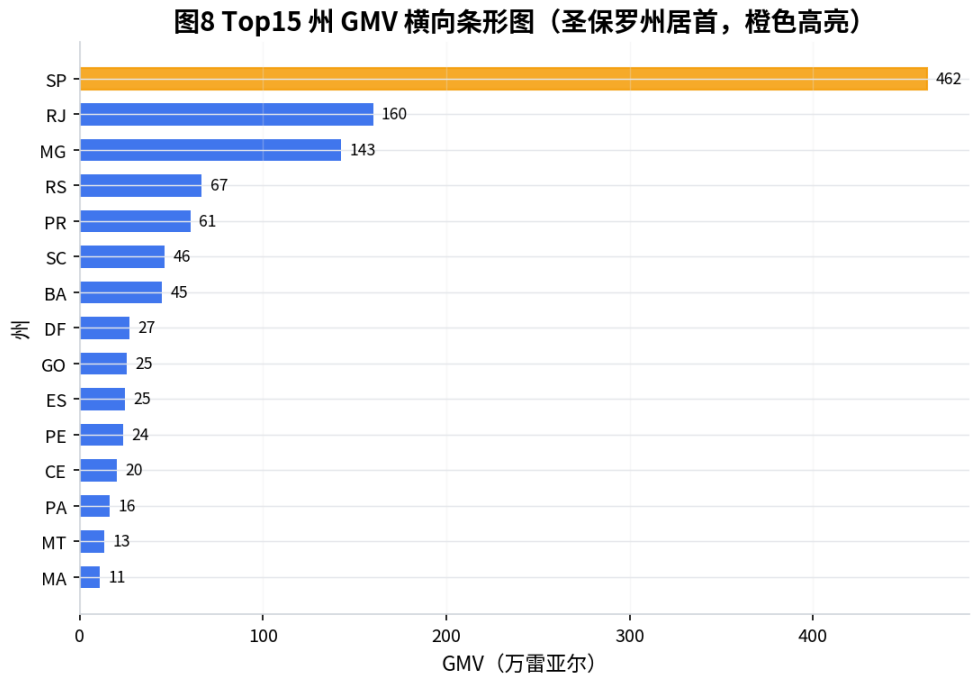


图 3　Top15 州 GMV 排行（圣保罗州占 38.2%）

5.2 可视化模板复现

在对照了《Excel 数据可视化——从图表到数据大屏》的典型模板后，本文使用 Matplotlib 复现了其中经典的 15 种图表（fig01–fig15）：折线趋势、柱线组合、帕累托、环形占比、堆叠面积、散点、直方、横向条形、玫瑰、漏斗、瀑布、雷达、热力、KPI 仪表卡与箱线图，覆盖趋势、对比、构成、分布、关系五大分析视角。复现时在图表类型、双轴布局、配色方案、数据标签与图例位置上贴近原模板，并统一 150dpi 分辨率、中文字体与 fig 编号命名。以图 4 帕累托图为例：柱体为品类 GMV、折线为累计占比、红色虚线为 80% 参考线，并额外标注了“前 10 个品类即覆盖 80% GMV”的关键读数，实现模板还原与信息增强的平衡。

对比 Excel 的实现，Python 复现的优势在于：数据更新后图表可一键重绘、样式参数可精确复用、11 万行明细下性能稳定；不足是个性化标注与微调需代码实现、交互性需借助 Pyecharts 等库补足。总体而言，Python 更适合需要批量复现与版本管理的工程化场景，Excel 更适合一次性快速探索。

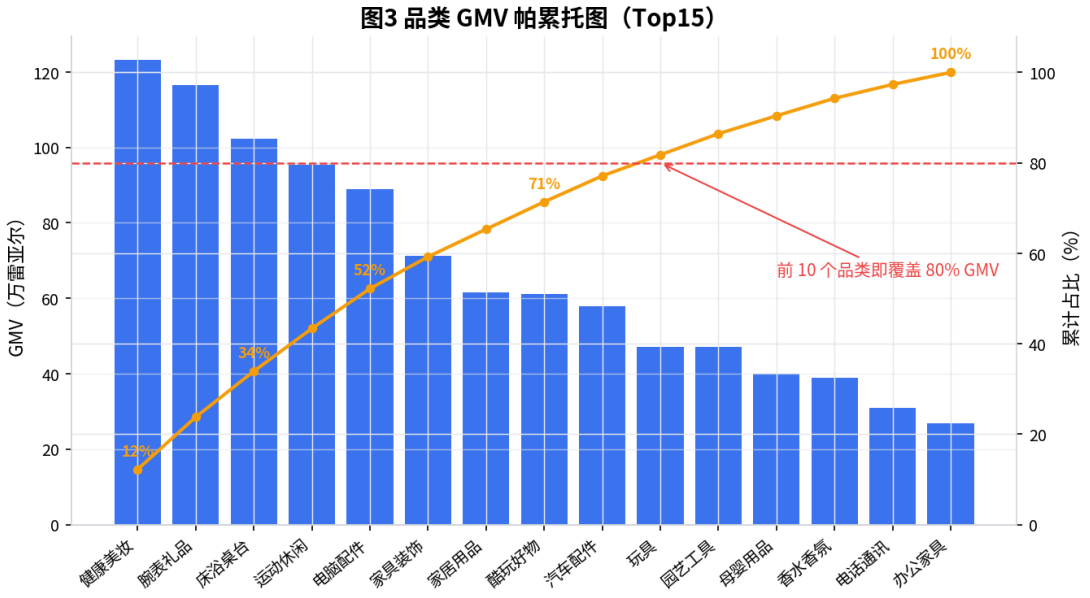


图 4　品类 GMV 帕累托图（模板复现示例）

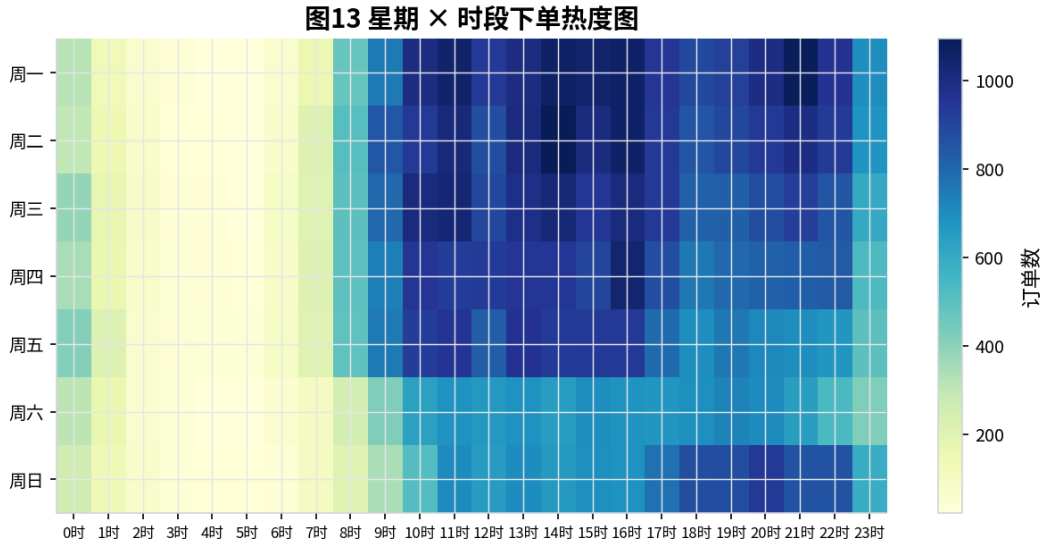


图 5　星期 × 时段下单热度图（工作日午间为高峰）

5.3 业务模型图

业务模型图与第 4 章模型一一对应（fig16–fig23）。图 6 的 RFM 气泡图以 F 为横轴、R 为纵轴、气泡大小表示 M，同时也在途中叠加了 R 中位数的切分线：客户密集堆积于 F=1 纵列，气泡在 R≤219 天与 R>219 天两个区域分别对应重要发展与重要挽留分层，直观显示“绝大多数客户只买一次”的结构性问题；F≥2 的复购客户虽稀疏，但气泡普遍更大，再次印证了复购与高消费的绑定关系。

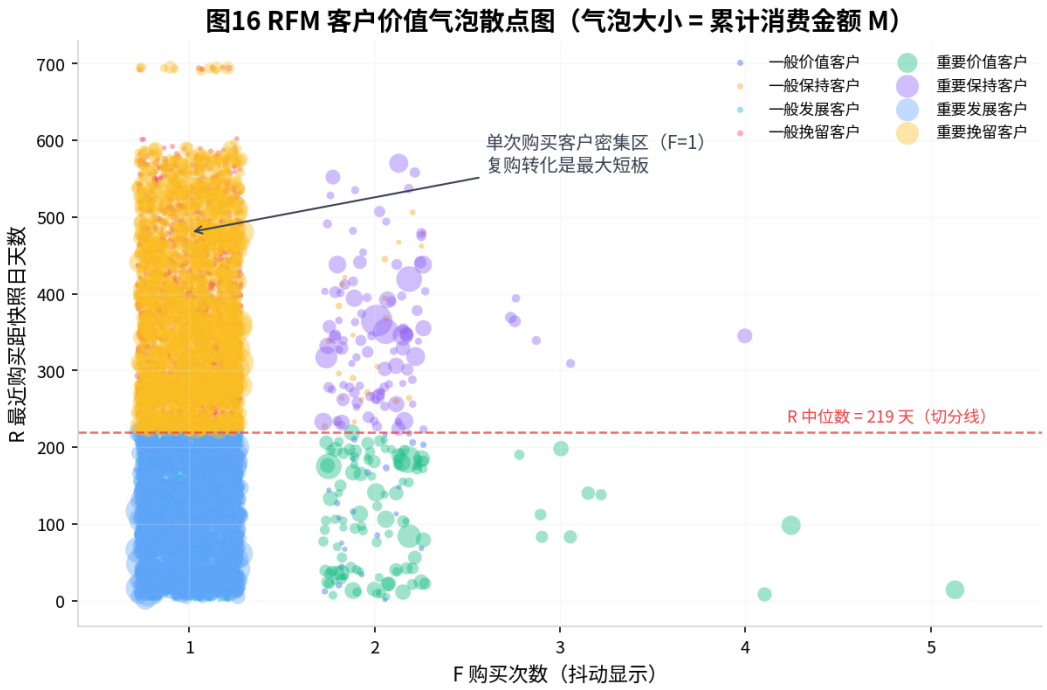


图 6　RFM 客户价值气泡散点图（含 R 切分线）

图 7 的八分类结构图采用“客户数柱 + GMV 占比线”双轴组合：四个人数过万的分层中，一般挽留与一般发展客户人均消费仅约 47 雷亚尔、GMV 占比均不足 9%，人数与价值明显错配；重要价值、重要保持两个人数最少的分层却拥有最高人均消费，是会员体系与专属服务的目标人群。图 8 的同期群热力图以首购月为行、月龄为列，首列 100% 之外迅速衰减至个位乃至千分位，且各群衰减形态一致，排除了季节性解释，指向平台复购机制的系统性缺失。

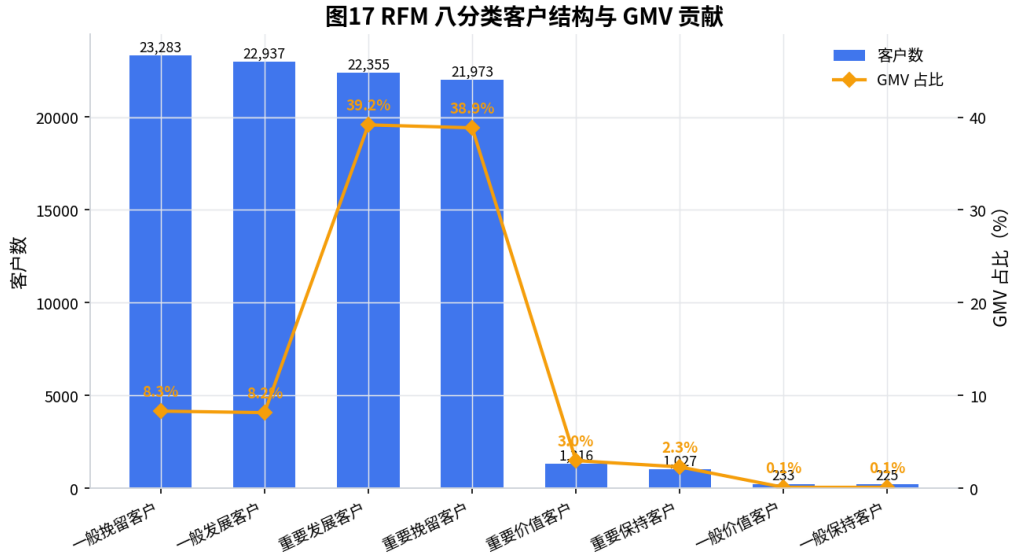


图 7　RFM 八分类客户结构与 GMV 贡献

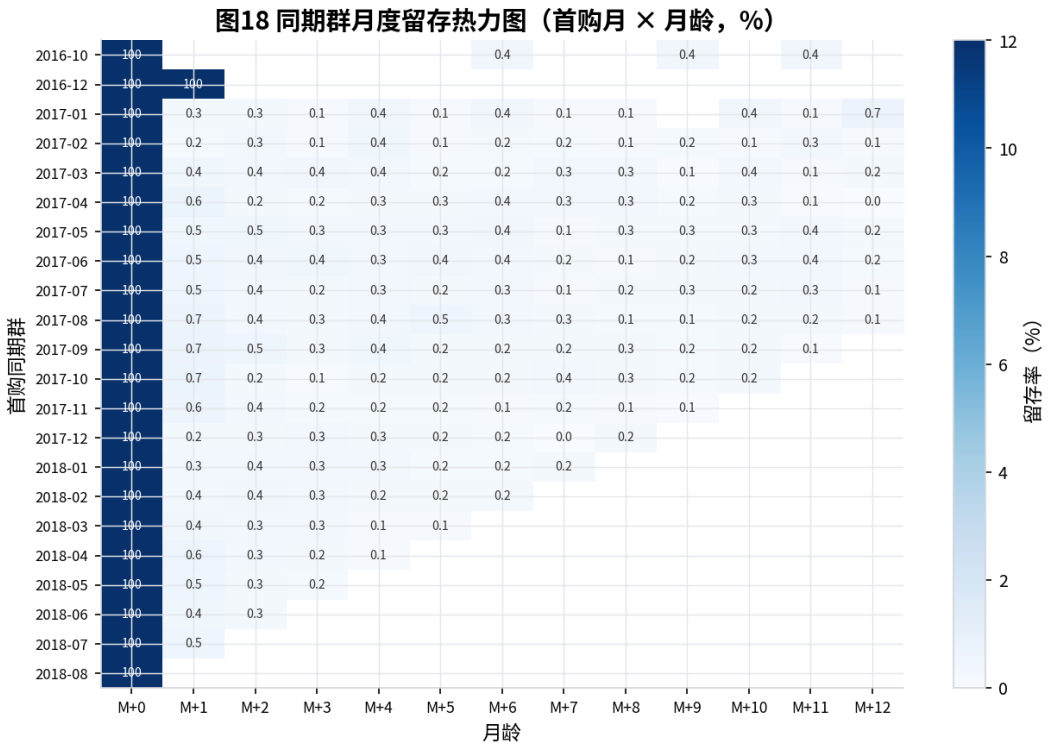


图 8　同期群月度留存热力图（首购月 × 月龄）

图 9 的波士顿矩阵以相对份额为横轴、同比增速为纵轴、气泡为 2018H1 GMV：健康美妆与腕表礼品两大现金牛以高份额、高于中位数的增速居右下；家居用品、汽车配件以橙色高亮，为最具加码价值的潜力品类；建筑工具份额低但增速畸高，主要是因为基数小的原因，在归入问题象限是需谨慎解读。图 10 的 SARIMA 预测图叠加 95% 置信区间，预测 2018 年 11 月峰值 98.7 万雷亚尔，与 2017 年同期实测峰值几乎持平，体现出了季节项有效性；而图 11 的回测对比进一步显示，误差主要集中于平台快速抬升的 3—5 月，进入平台期后预测贴合实际。

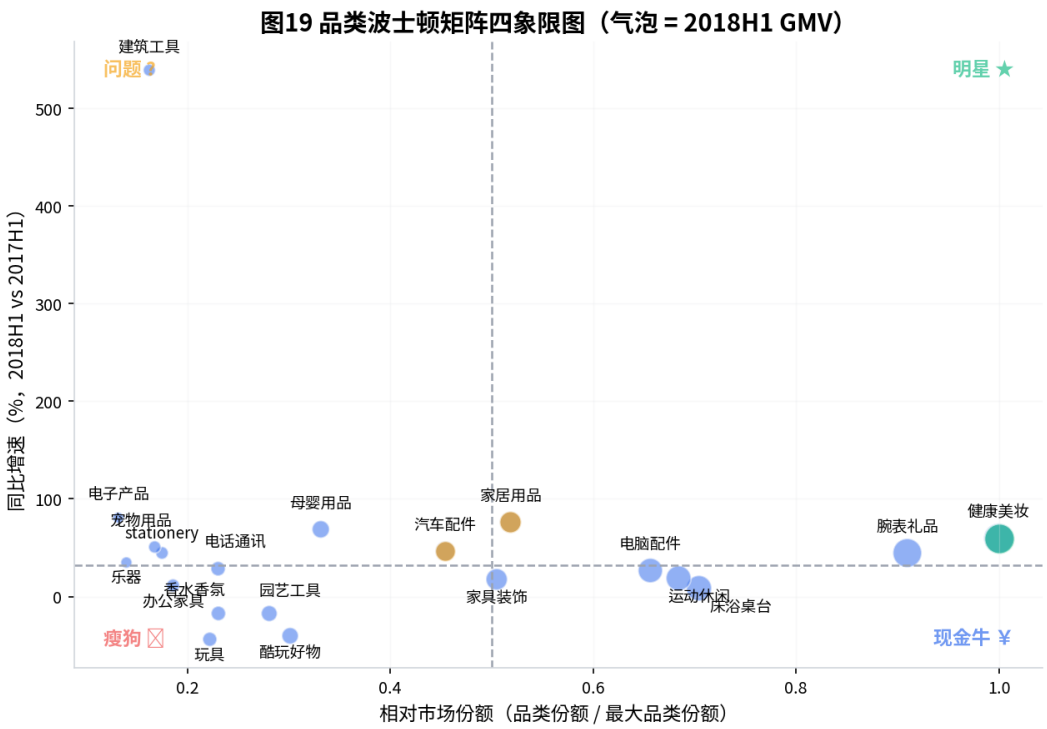


图 9　品类波士顿矩阵四象限图（气泡 = 2018H1 GMV）

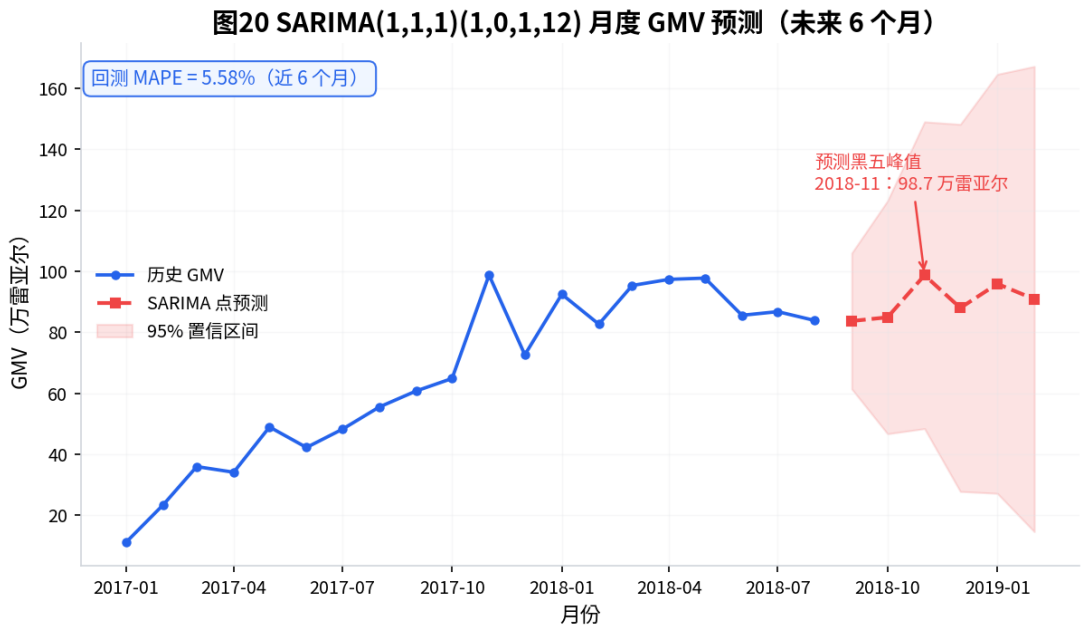


图 10　SARIMA 月度 GMV 预测（含 95% 置信区间）

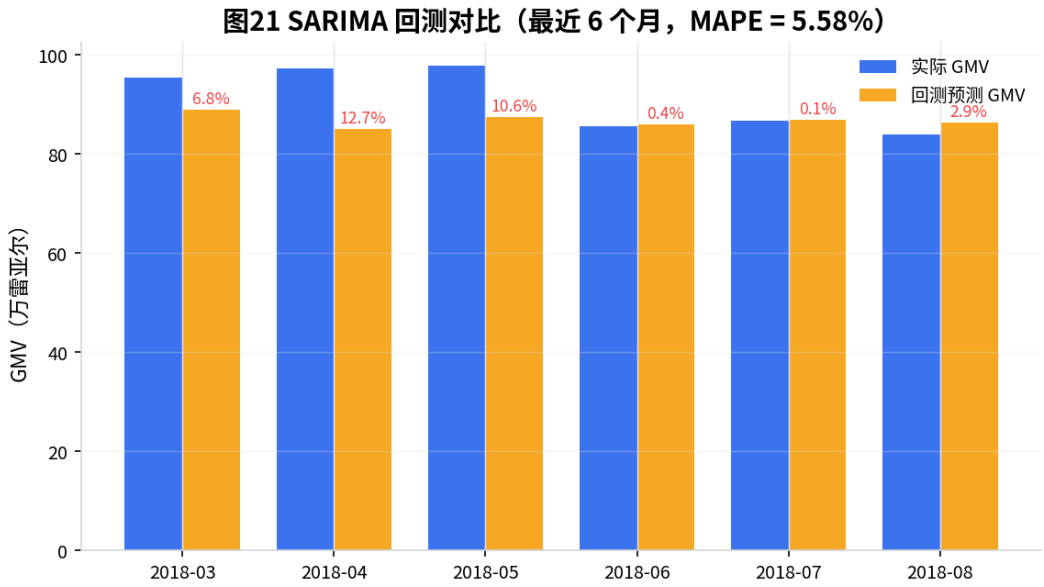


图 11　SARIMA 回测：实际 vs 预测（MAPE=5.58%）

图 12 的关联规则散点以支持度为横轴、置信度为纵轴、气泡与颜色共同编码 lift，右上区域的“家居舒适→床浴桌台”兼具高置信度与高提升度，是最优先落地的推荐规则；图 13 的 ABC 累计曲线（洛伦兹形态）显示前 45% 客户贡献 80% GMV，曲线与绝对平均线之间的面积直观度量了价值集中度，为差异化运营提供了量化依据。

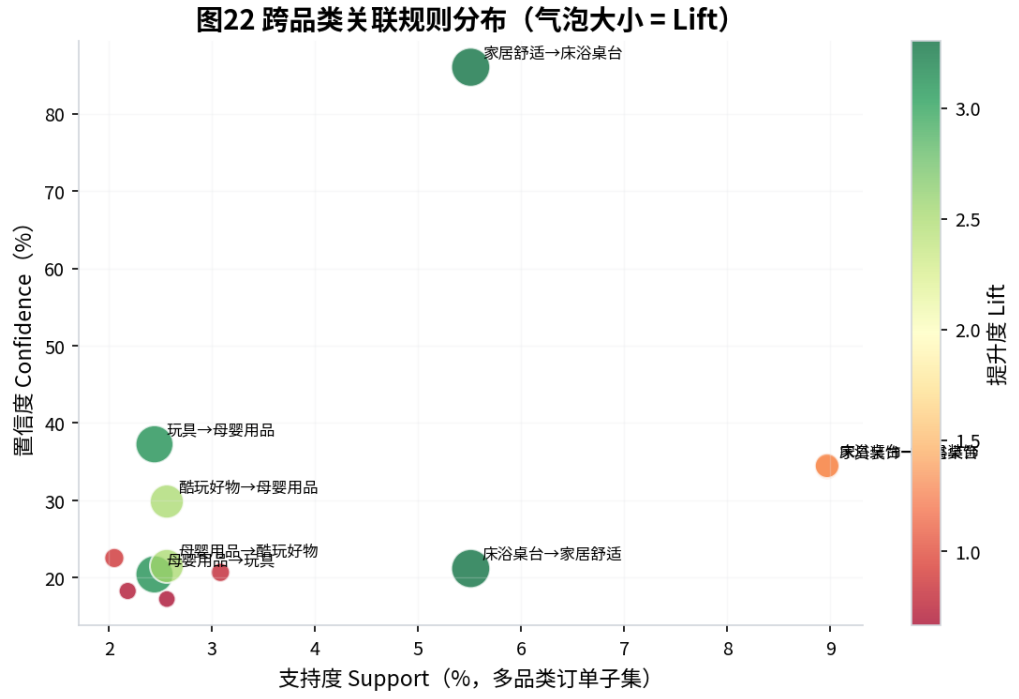


图 12　跨品类关联规则分布图（气泡/颜色 ＝Lift）

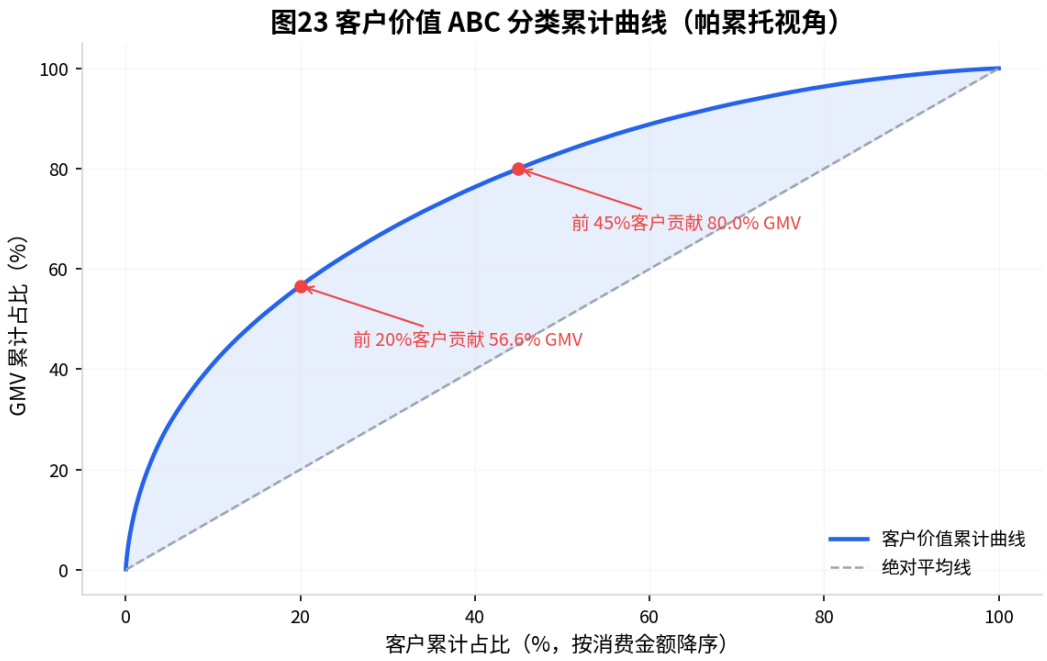


图 13　客户价值 ABC 分类累计曲线

5.4 交互式可视化大屏

同时项目也基于 Pyecharts 构建了一个暗色主题交互大屏（图 14，outputs/fig24_交互式可视化大屏.html）。在页面顶部设置总标题、数据时间范围与口径说明，并以 6 项 KPI 汇总累计 GMV、成交订单、独立客户、客单价、好评率和复购率；主体按“经营总览—品类与交易结构—客户价值—预测与商业决策”四个分区组织 14 个分析组件，包含 13 个图表与 1 张明细表。在原有趋势缩放、支付结构、日历热力、履约漏斗和季度时间轴基础上，新增的 BCG 增长—份额矩阵、Apriori 关联规则、RFM 八分类 GMV 贡献、同期群留存热力图与 SARIMA 预测图。预测图同时呈现未来 6 个月点预测和 95% 置信区间，并展示回测 MAPE=5.58%、RMSE=7.16 万雷亚尔及黑五备货建议。交互方面，除悬停提示、图例筛选、区域缩放和季度联动外，点击 Top10 条形或 BCG 气泡即可下钻查看对应品类的 GMV、订单量、客单价、评分和交付时效。全部组件由 Python 代码生成，未使用 Power BI、Tableau 等任何 BI 软件，亦未使用 Excel 图表截图。



图 14　交互式商业分析可视化大屏（14 个分析组件）

6 商业案例分析

6.1 案例背景

设想本文读者为 Olist 平台运营团队：因为平台正处于 GMV 高速扩张期，但拉到新客的成本随竞争加剧而上升，管理层需要在“继续拉新”与“盘活存量”之间分配预算，并为即将到来的黑五大促制定品类与备货策略。以下解读与建议均

基于前述真实数据与模型结果。

6.2 结果解读

第一，增长质量与增长速度不匹配。在 GMV 同比 +181.6% 的同时，复购的客户占比仅 3.0%、次月留存 5.45%、在 12 个月后留存的客户量趋近于零，增长几乎全部由新客的一次性购买来带动。更值得警惕的是， 2018 年 6—8 月 GMV 已进入平台期——当新客红利见顶而留存机制缺位，增长失速风险将直接暴露，客户资产沉淀属于是当前最优先的课题。

第二，客户价值呈“厚尾”分布且存在明确召回空间。前 45% 客户贡献了 80% GMV；其中 21,973 名重要挽留客户人均历史消费可达 233.71 雷亚尔、合计沉淀 38.85% 的历史 GMV，但已平均 365 天未回购，是召回投入产出比最高的群体；1,316 名重要价值客户，人均 299.87 雷亚尔、平均购买 2.16 次，则证明了复购路径的单位经济可行性，其品类偏好可反向指导复购商品池设计。

第三，品类组合分化明显，结构与关联结论互补。健康美妆（份额 10.5%、增速 +59.5%）与腕表礼品构成现金牛；家居用品（+76.1%）、汽车配件（+46.4%）具备明星潜质；玩具、酷玩好物落入瘦狗象限。关联规则进一步给出跨品类抓手：家居舒适与床浴桌台的强关联（lift=3.30）恰好落在现金牛与明星品类的邻接带上，搭配营销可同时放大两个象限的价值。

第四，运营节奏可由预测与行为规律精确校准。SARIMA 预测黑五峰值约 98.7 万雷亚尔，与历史峰值同量级；叠加“工作日 10—16 时下单高峰、圣保罗州占 38.2%、信用卡支付占 79.3%”的行为结构，大促的库存、流量、客服与物流资源均可按量化口径提前配置，而非根据经验进行调配。

6.3 商业建议

建议一：启动重要挽留客户召回计划。对 21,973 名重要挽留客户按历史品类偏好定向推送回归优惠券与新品通知——该群体人均消费 233.71 雷亚尔且已验证购买力，按人均历史 GMV 估算，该群体合计历史 GMV 约为 513.5 万雷亚尔， 10% 召回率对应的存量价值约为 51 万雷亚尔，成本远低于同规模拉新。

建议二：建设复购与会员体系，改善留存曲线。针对次月留存仅 5.45% 的短板，在签收后 30 天窗口内推送关联品类券（依托建议四的关联规则），并试点免邮会员；目标将复购客户占比从 3.0% 提升至 5% 以上、次月留存翻倍至 10%，以 1,316 名重要价值客户的行为画像作为复购商品池与权益设计的基准。

建议三：优化品类资源分配。对健康美妆、腕表礼品两大现金牛保障供给与流量基本盘；将增量预算向家居用品、汽车配件等双高品类倾斜；对玩具、酷玩好物等瘦狗品类收缩 SKU 或转为长尾代销，释放运营资源；建筑工具等高增速低基数品类先行小步试错，避免被增速表象误导。

建议四：落地搭配营销与捆绑销售。依据关联规则，在家居舒适品类详情页推荐床浴桌台商品（置信度 86%），对母婴与玩具品类设计组合装与满减门槛，直接提升客单价（当前 160 雷亚尔）与单笔件数（当前约 1.2 件），并借搭配复购反哺建议二的留存目标。

建议五：按 SARIMA 预测指导大促备货与物流布仓。模型预测 2018 年 11 月 GMV 将达 98.7 万雷亚尔，应提前 6—8 周锁定现金牛与明星品类库存；针对圣保罗州 38.2% 的订单集中度优化前置仓布局，将平均配送时长从 12.1 天进一步压缩，支撑好评率（当前 78.4%）与复购率同步提升。

7 结论与展望

7.1 研究结论

回顾全文，本文主要基于 Olist 真实电商数据完成了端到端商业数据分析：以合规方式获取并治理 11 万行级多表数据，应用六种模型得出一致指向的结论——平台正处于“高增长、低留存”的关键窗口期，增长质量提升的空间远大于规模扩张；RFM 与 ABC 模型锁定了最值得运营的三大客群，BCG 与关联规则给出了品类与搭配策略，SARIMA 以 5.58% 的回测误差为备货提供了量化依据。23 张图表与 14 组件大屏全部由 Python 复现，验证了课程技术栈在真实业务场景中的完整可用性。

7.2 局限性与展望

本研究存在三点局限：其一，数据止于 2018 年 8 月，SARIMA 训练序列

仅 20 个月，长期预测置信区间较宽，未来可引入 Prophet 或梯度提升模型对比；其二，Olist 单均件数约 1.2 件，关联规则只能在多品类订单子集上挖掘，结论外推需谨慎；其三，评价文本为葡萄牙语，中文情感分析工具链（snownlp/jieba）不适用，后续可引入多语言预训练模型开展舆情分析。此外，大屏以独立 HTML 交付，已实现季度联动与品类下钻，但尚未连接在线数据库；未来可迁移至 Streamlit 并增加跨图表条件筛选。

7.3 AI 使用披露

（1）AI 辅助范围。本文在代码调试、图表样式调优、交互事件排查、文字润色与结构建议等环节使用了 AI 助手 Kimi。典型问题包括 mlxtend 的 Apriori 支持度阈值设定、statsmodels SARIMA 的 95% 置信区间与 MAPE/RMSE 输出、Matplotlib 中文字体与 RFM 气泡图着色，以及 Pyecharts 图表嵌入和点击下钻事件调试。AI 主要提供候选方案与修改建议，具体代码均经过本机环境运行验证。

（2）交互界面部署。大屏采用“本地复现—平台预览—手动发布”的交付路径。本地复现时，在项目根目录执行 pip install -r requirements.txt 和 python run_all.py，由 scripts/05_dashboard.py 读取 outputs/tables/ 的结果表，生成 outputs/fig24_交互式可视化大屏.html；该文件为自包含静态页面，可直接使用 Chrome、Edge 等浏览器打开，无需启动后端服务。平台预览时，将页面保存为 Kimi 协助构建应用的网站版本，对应的链接为：https://dhnfslgrqvjuc.ok.kimi.link。发布后的页面仍使用生成时写入的静态分析结果，不连接在线数据库。

（3）人工核验与责任边界。数据获取、清洗、模型计算和图表生成均由仓库中的可复现代码完成；AI 未替代数据源核验与业务判断，不存在由 AI 伪造数据或直接生成未经核验结论的情形。部署环节中，AI 辅助整理 HTML 结构、排查交互事件并撰写部署说明，版本保存、公网发布和最终提交均以实际页面状态及人工操作为准。

参考文献

[1] Olist. Brazilian E-Commerce Public Dataset[DS]. Kaggle, 2018. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

[2] 《Excel 数据可视化——从图表到数据大屏》[M]. 课程指定参考书.

[3] 黄成明. 数据化管理：洞悉零售及电子商务运营[M]. 北京: 电子工业出版社, 2014.

[4] 陈东清, 叶翀, 黄章树. 基于熵权法改进 RFM 模型的电商客户价值细分研究[J]. 西安电子科技大学学报(社会科学版), 2020(2): 39-45.

[5] 易丹辉, 王燕. 应用时间序列分析[M]. 5 版. 北京: 中国人民大学出版社, 2019.

[6] Box G E P, Jenkins G M, Reinsel G C. Time Series Analysis: Forecasting and Control[M]. 5th ed. Wiley, 2015.

[7] Agrawal R, Srikant R. Fast algorithms for mining association rules in large databases[C]//Proceedings of VLDB. 1994: 487-499.

[8] 陈为, 沈则潜, 陶煜波. 数据可视化[M]. 北京: 电子工业出版社, 2013.

[9] 任磊, 杜一, 马帅, 张小龙, 戴国忠. 大数据可视分析综述[J]. 软件学报, 2014, 25(9): 1909-1936.

[10] 张良均, 谭立云, 刘名军, 江建明. Python 数据分析与挖掘实战[M]. 2 版. 北京: 机械工业出版社, 2019.

附录

A 核心代码片段

```
# RFM 八分类核心逻辑（scripts/03_analysis_models.py）
snapshot = d['order_purchase_timestamp'].max() + pd.Timedelta(days=1)
rfm['R 高'] = (rfm['R_最近购买距今天数'] <= r_med).astype(int)   # 中位数切分
rfm['F 高'] = (rfm['F_购买次数'] > 1).astype(int)                  # 复购=高（业务依据）
rfm['M 高'] = (rfm['M_累计消费金额'] > m_med).astype(int)
rfm['客户分层'] = [SEG_MAP[(r,f,m)] for r,f,m in rfm[['R 高','F 高','M 高']].values]


# SARIMA 回测与预测（scripts/03_analysis_models.py）
fit = SARIMAX(train, order=(1,1,1), seasonal_order=(1,0,1,12),
              enforce_stationarity=False, enforce_invertibility=False).fit()
fc = fit.get_forecast(6)   # 点预测 + conf_int(alpha=0.05) 95% 置信区间
mape = (abs((test - fc.predicted_mean) / test)).mean() * 100   # 回测 MAPE
```

B GitHub 仓库链接与目录结构

仓库链接：https://github.com/sheelor/olist-ecommerce-analysis

目录结构：data/raw/（首次运行自动下载 8 张原始 CSV，同时地理编码表不参与本分析）、data/clean/（清洗产物与 SQLite）、scripts/（00_download_data 至 05_dashboard 六个脚本）、outputs/figures/（fig01–fig24）、outputs/tables/（9 张结果表）、docs/（数据来源合规声明、schema 说明、图表索引）、requirements.txt、run_all.py（一键复现入口）、README.md。

复现方式：pip install -r requirements.txt 后执行 python run_all.py，约 3–5 分钟即可重新生成全部图表、结果表与大屏。

C 图表索引（fig01–fig24+ 大屏截图）

编号	图表名称	类别
fig01–fig02	月度 GMV 趋势折线图 / GMV 环比柱线组合图	模板复现
fig03–fig05	品类 GMV 帕累托图 / 品类占比环形图 / 品类结构堆叠面积图	模板复现

fig06–fig08	价格与运费散点图 / 订单金额直方图 / Top15 州横向条形图	模板复现
fig09–fig11	评分分布玫瑰图 / 订单履约漏斗图 / GMV 构成瀑布图	模板复现
fig12–fig15	品类雷达图 / 时段星期热力图 / 核心 KPI 仪表卡 / 品类价格箱线图	模板复现
fig16–fig17	RFM 气泡散点图 / RFM 八分类客户结构图	业务模型
fig18–fig19	同期群留存热力图 / 波士顿矩阵四象限图	业务模型
fig20–fig21	SARIMA 预测含置信区间图 / SARIMA 回测对比图	业务模型
fig22–fig23	关联规则分布图 / 客户价值 ABC 累计曲线	业务模型
fig24	交互式可视化大屏（14 个分析组件，HTML）及截图	交互大屏